

Financial Agent Harness

Dari Command Harness Menuju
Natural-Language-First Architecture

Revisi arsitektur atas Dokumen Desain v1.0, disusun berdasarkan diskusi lanjutan mengenai kebebasan interaksi pengguna, batas agent authoring, dan prioritas roadmap menjelang hackathon.

Revisi v1.2 mengunci tiga hal yang masih longgar di v1.1: (1) Intent Router dibangun berbasis LLM sejak Minggu 1 — dibatasi ke structured intent, bukan tahap rule-based lalu migrasi; (2) pemetaan tool eksplisit ke API Sectors, disusun dari audit dokumentasi API langsung; (3) batas Agent Configurator diperjelas dengan contoh konkret yang dilarang.

Daftar Isi

- 01 Ringkasan Perubahan dari v1.0
- 02 Prinsip Tambahan: Natural-Language-First
- 03 Arsitektur Revisi: Intent Router & Template Library
- 04 Command Sebagai Shortcut, Bukan Satu-satunya Pintu
- 05 Agent Configurator (Custom Agent Terbatas)
- 06 Agent Library: Memperluas Cakupan, Bukan Membuka Otorship Bebas
- 07 Reframing /screen & Catatan Regulasi
- 08 Pemetaan Tool: API Sectors → Agent
- 09 Revisi Roadmap 4 Minggu
- 10 Risiko Tambahan & Kesimpulan

BAGIAN 01

Ringkasan Perubahan dari v1.0

Dokumen v1.0 memposisikan sistem sebagai kumpulan command tetap (`/judge`, `/compare`, dst.) dengan execution graph yang di-hardcode per command. Diskusi lanjutan mengangkat pertanyaan mendasar: apakah ini benar-benar sebuah *harness*, atau sekadar katalog fitur yang dibungkus tampilan command-line?

Kesimpulannya: keresahan itu valid — tapi solusinya bukan menghapus struktur dan membiarkan planner menyusun apa pun secara bebas. Justru sebaliknya: **empat pilar desain v1.0 dipertahankan penuh** (evidence-first, raw data tidak pernah dikirim antar-agent, structured intermediate output, debate terbatas). Yang berubah adalah **titik masuk** sistem — dari “user harus tahu nama command” menjadi “user bertanya bebas, sistem yang merutekan ke pipeline yang tepat” — tanpa planner kehilangan batasnya.

Apa yang tetap, apa yang berubah

Tetap dari v1.0	Berubah di v1.2
Evidence Store & evidence ID wajib di tiap klaim	Titik masuk: natural language jadi jalur utama, command jadi shortcut
Structured claim → evidence → confidence kategorikal	Prioritas command: /screen naik dari roadmap menjadi MVP
Bull / Bear / Debate maksimum 2 ronde	Definisi “custom agent”: dari wacana bebas menjadi Agent Configurator terbatas
Judge dengan rubrik bobot eksplisit & deterministik	Reframing output <code>/screen</code> : dari implikasi prediksi ke kriteria historis objektif
Empat pilar desain (Bagian 03, v1.0)	Alokasi roadmap 4 minggu disesuaikan (Bagian 09 addendum ini)

Perubahan tambahan di v1.2

Tetap dari v1.1	Berubah di v1.2
Intent Router hanya memilih dari Template Library, tidak pernah menyusun graph baru	Cara mencapainya: LLM classifier dipakai sejak Minggu 1 , dibatasi ketat ke structured intent output — bukan rule-based dulu baru migrasi ke LLM di Minggu 3 (Bagian 09)
Agent Configurator terbatas ke pilihan yang sudah tervalidasi (Bagian 05)	Ditambah contoh eksplisit yang <i>dilarang</i> , supaya batas “checklist kurasi vs instruksi bebas” tidak ambigu saat ditulis ulang ke spec (Bagian 05)
Sectors API → Financial Researcher (given, belum dirinci)	Pemetaan tool eksplisit per agent, hasil audit langsung ke dokumentasi API, termasuk daftar yang secara sadar di-skip (Bagian 08, baru)

BAGIAN 02

Prinsip Tambahan: Natural-Language-First

“**Harness**” dan “**kebebasan penuh untuk user**” adalah dua sumbu yang berbeda. Sebuah test harness bersifat fleksibel bukan karena test yang dijalankan bisa berupa apa saja tanpa batas, melainkan karena ia punya struktur yang bisa diisi banyak test case. Fleksibilitas ada pada *komposabilitas primitives*, bukan pada *ketiadaan struktur*. Prinsip ini yang dipakai untuk merevisi arsitektur interaksi Financial Agent Harness.

Prinsip ke-5: Natural-Language-First, Command sebagai Shortcut. User tidak perlu menghafal sintaks command untuk memakai sistem — cukup bertanya dengan bahasa natural. Command tetap ada sebagai jalur cepat bagi power user, menembak ke template eksekusi yang persis sama dengan yang dipakai jalur natural language.

Spektrum kebebasan interaksi

Empat level berikut dipakai sebagai referensi untuk menentukan seberapa jauh kebebasan dibuka di tiap fase — supaya “kebebasan” tidak jadi keputusan sekali jalan yang mengorbankan auditability.


Level	Deskripsi	Status di v1.2
L0	User harus tahu nama & sintaks command persis	Digantikan — command jadi opsional, bukan satu-satunya jalur
L1	NL bebas → Intent Router mengklasifikasi ke template + extract parameter	Scope v1.2 — dibangun untuk hackathon
L2	Planner menyusun urutan dari node primitif mengikuti aturan komposisi	Roadmap v1.2 — dicoba bila waktu Minggu 4 tersisa
L3	Drag-and-drop graph builder, agent authoring API/skill bebas	Visi jangka panjang — di- <i>pitch</i> , tidak dibangun

Router pada L1 **tidak pernah** mengarang urutan agent baru dari nol — ia hanya memilih satu dari sejumlah template yang sudah tervalidasi. Ini menjaga auditability dan cost control dari v1.0 tetap utuh, sekaligus menjawab keresahan bahwa sistem “belum terasa seperti harness”.

BAGIAN 03

Arsitektur Revisi: Intent Router & Template Library

Titik masuk sistem sekarang bercabang dua — natural language atau slash command — tetapi keduanya berujung pada komponen baru, **Intent Router**, sebelum masuk ke execution graph yang sama seperti v1.0 (Bagian 04).



Gambar A1 — Intent Router menembak ke template yang sama, dari dua pintu masuk berbeda

Peran Intent Router

Aspek	Detail
Input	Pertanyaan bebas (natural language) ATAU slash command eksplisit
Proses	Klasifikasi intent ke satu template yang sudah ada + extract parameter (ticker, kriteria, sektor, dsb.) — pola yang sama dengan cara claim divalidasi terhadap evidence_id: structured output classification, bukan generative planning bebas
Output normal	Nama template + parameter terisi → dieksekusi seperti execution graph v1.0
Output bila tidak yakin	Mengajukan pertanyaan klarifikasi ke user — tidak mengarang graph baru
Yang tidak dilakukan	Menyusun urutan agent baru dari nol, atau memanggil agent di luar Template & Agent Library yang sudah tervalidasi

Contoh output Intent Router (v1.2): untuk pertanyaan “Apakah BBKA layak dikoleksi, dengan analisis mendalam?”, Router hanya mengeluarkan JSON terstruktur — {"intent": "company_judgment", "ticker": "BBKA", "depth": "deep", "include_debate": true} — yang lalu di-mapping ke template **JUDGE_DEEP** yang sudah didefinisikan tim. LLM tidak pernah diminta menjawab “agent apa saja yang perlu dipanggil”, hanya “template mana yang cocok”. Pendekatan ini dipakai **sejak Minggu 1** (lihat revisi roadmap, Bagian 09) — bukan tahap rule-based yang bermigrasi ke LLM di

pertengahan proyek, karena pergantian pendekatan di tengah jalan berisiko: kalau versi awal ternyata rapuh, itu baru ketahuan saat waktu sudah mepet ke UI/robustness.

BAGIAN 04

Command Sebagai Shortcut, Bukan Satu-satunya Pintu

Command tidak dihapus — ia tetap berguna sebagai jalur cepat bagi power user yang sudah hafal sintaksnya. Yang berubah hanya prioritas build, mengikuti kebutuhan riil yang muncul dari contoh penggunaan (“saham apa yang konsisten naik” = kebutuhan `/screen`, bukan kebutuhan agent authoring bebas).

Command	Deskripsi	Contoh trigger NL	Prioritas v1.2
<code>/judge</code>	Evaluasi investasi 1 ticker	“Apakah BBCA layak dikoleksi?”	MVP — Minggu 1–2 (<i>tidak berubah</i>)
<code>/screen</code>	Saring saham lintas ticker berdasar kriteria	“Saham apa yang konsisten tumbuh?”	Naik ke MVP — Minggu 2–3 (semula “didesain, belum diimplementasi”)
<code>/compare</code>	Bandingkan beberapa ticker sejenis	“BBCA vs BBRI vs BMRI, mana lebih baik?”	MVP — Minggu 4 (<i>tidak berubah</i>)
<code>/research</code>	Riset mentah tanpa opini/skor	“Apa yang terjadi di BBCA minggu ini?”	Roadmap — kandidat kuat Minggu 4 (reuse Researcher)
<code>/investigate</code>	Selidiki pergerakan harga tak biasa	“Kenapa BBCA naik tajam hari ini?”	Roadmap, didesain & di- <i>pitch</i>
<code>/challenge</code>	Uji satu klaim spesifik dari user	“Menurutmu BBCA overvalued, benar?”	Roadmap, didesain & di- <i>pitch</i>

Catatan: Intent Router dan slash command tidak menjalankan dua logic terpisah — keduanya menembak ke template Graph yang persis sama (Bagian 03). Tidak ada duplikasi implementasi antara “mode command” dan “mode natural language”.

BAGIAN 05

Agent Configurator (Custom Agent Terbatas)

Kebutuhan “user bisa membuat agent baru” dipenuhi lewat **Agent Configurator** — kombinasi pilihan dari komponen yang sudah tervalidasi, bukan authoring bebas (prompt bebas, API bebas). Hasilnya tetap terasa seperti “membuat analyst sendiri”, tapi secara teknis adalah instance baru dari template yang sudah ada dengan parameter berbeda — sehingga tetap patuh ke skema claim → evidence_id yang menjaga auditability.

Bisa dikonfigurasi user	Tidak dibuka ke user (di v1.2)
Domain fokus (mis. banking, consumer, mining — dari daftar sektor yang sudah didukung Sectors API)	Endpoint API bebas / sumber data di luar yang sudah terhubung ke Evidence Store
Data source — checklist dari sumber yang sudah terhubung (Sectors, News feed)	Prompt / system instruction bebas untuk agent
Skill / modul analisis — checklist dari modul yang sudah dibangun (valuation, sentiment, dividend, dsb.)	Skill baru yang belum ada implementasinya di sistem
Nama & deskripsi agent (label tampilan saja)	Struktur output di luar skema claim → evidence_id

Batas eksplisit: Free-form agent authoring (API benar-benar bebas, skill benar-benar baru) tetap dicatat sebagai visi produk (L3, Bagian 02), tapi eksplisit di luar scope hackathon. Disebutkan di pitch sebagai arah pengembangan — pola yang sama dengan bagaimana v1.0 memperlakukan **/challenge** dan **/screen**: didesain, tidak wajib berfungsi penuh saat demo.

Contoh konkret yang TIDAK diperbolehkan (ditambahkan di v1.2 setelah ditemukan ambigu dalam diskusi desain):
UI Configurator yang menyediakan field bebas seperti “Instructions: Analyze banking-specific indicators however you see fit...” — itu instruksi/prompt bebas, persis yang dilarang di tabel atas. Bentuk yang benar: user memilih domain (mis. Banking) lalu mencentang skill/modul yang **sudah ada implementasinya** (Fundamental Analysis, Valuation, Foreign Flow), tanpa kolom teks bebas sama sekali. Kalau UI punya kolom yang menerima kalimat instruksi apa pun dari user, itu sinyal desainnya sudah keluar dari batas v1.2.

BAGIAN 06

Agent Library: Memperluas Cakupan, Bukan Membuka Otorship Bebas

Kebutuhan akan “banyak agent spesifik” (pengumpul data menyeluruh, agent berita khusus satu sektor, dst.) dijawab lewat Agent Library yang tumbuh — ditambah oleh **tim**, secara inkremental, bukan diotorisasi bebas oleh user. Ini memperluas Bagian 09 v1.0 (Agent Ekstensi) tanpa membuka risiko integrasi atau evidence hallucination yang datang dari user authoring.

Agent Inti (selalu aktif)	Agent Library (dipilih via Configurator / --with)
Financial Researcher	Dividend Analyst
Market Researcher	Insider Activity Analyst
News Researcher	Sector Analyst
Bull / Bear Agent	Macro Analyst
Judge Agent	Technical Analyst, Risk Analyst
	Sector News Agent (baru) — filter berita relevan ke satu sektor spesifik, bukan seluruh pasar
	Cross-Market Signal Agent (baru) — mengaitkan sinyal antar sektor, mis. suku bunga → perbankan

Menambah agent baru ke Library berarti tim mendefinisikan template + skema evidence-nya sekali, lalu tersedia untuk semua user lewat Configurator. Ini jauh lebih murah dan aman dibanding infrastruktur agent authoring bebas per-user (Bagian 05), sekaligus tetap menjawab kebutuhan variasi agent yang luas.

BAGIAN 07

Reframing /screen & Catatan Regulasi

/screen naik prioritas karena langsung menjawab kebutuhan riil (“saham apa yang konsisten naik”). Tapi framing outputnya perlu diubah — pertanyaan asli mengandung implikasi *prediksi harga masa depan*, yang levelnya lebih sensitif secara regulasi (ranah OJK di Indonesia) dibanding skor evaluasi satu ticker di /judge yang sudah punya disclaimer.

	Sebelum (berisiko)	Sesudah — v1.2
Framing pertanyaan	“Saham yang akan naik konsisten”	“Saham dengan riwayat pertumbuhan laba/margin konsisten N kuartal terakhir”
Implikasi	Prediksi harga ke depan	Pola historis terukur, tertaut evidence
Bentuk output	Ranking + implikasi “beli”	Ranking + kriteria yang terpenuhi + evidence per kriteria

Wajib sebelum /screen didemokan: disclaimer yang lebih menonjol dibanding /judge — bukan hanya di footer, tapi ditampilkan berdekatan dengan setiap hasil ranking, karena sifatnya cross-ticker dan lebih dekat ke “rekomendasi daftar saham” dibanding evaluasi satu ticker.

BAGIAN 08

Pemetaan Tool: API Sectors → Agent

v1.1 menyebut “Sectors API → Financial Researcher” sebagai given, tanpa rincian endpoint. Bagian ini menguncinya berdasarkan audit langsung ke dokumentasi API Sectors (bukan hanya nama endpoint), supaya tidak ada tool yang dicari agent tapi ternyata tidak ada, dan tidak ada endpoint yang dipakai di luar kebutuhan /judge & /screen.

Agent	Tool (endpoint API Sectors) — status
Financial Researcher	Company Report ✓ · Quarterly Financials ✓ · Company Segments ✓
Market Researcher	Daily Transaction ✓ · Foreign Flow by Symbol ✓ · Broker Summary Top ● opsional (memperkaya “kenapa” di balik foreign flow, bukan blocker MVP)
Supporting (bukan evidence utama)	Broker Registry ✓ — tabel lookup broker_code → nama/origin, ditarik sekali & di-cache, dipakai mempercantik output Market Researcher
News & Filings Researcher	News ✓ · Filings ✓ · Suspensions ● jika memang diperlukan. <i>Catatan:</i> tidak ada endpoint “Corporate Actions” yang terdokumentasi di grup ini — jangan dimasukkan ke spec sampai nama endpoint pastinya terverifikasi.
Screener	Company Screener ✓ — pintu masuk /screen; Industries/Subindustries/Tags diperlakukan sebagai metadata/helper input untuk Screener, bukan tool agent tersendiri

Sengaja tidak dipakai di MVP (disimpan sebagai visi produk, pola sama dengan /investigate & /challenge): Top Brokers market-wide (ranking harian se-market, tidak menempel ke satu ticker/claim — jadi ide agent baru “Broker Activity Analyst” di Agent Library), seluruh endpoint SGX & KLSE (menambah currency handling, skema Evidence Store baru, testing regulasi lain — jauh lebih berat dari sekadar opsi Configurator baru), dan Mining Extension 13 endpoint (kecuali skenario ticker demo memang perusahaan tambang, di mana 1–2 endpoint seperti commodity-price bisa jadi evidence tambahan untuk Sector Analyst).

Catatan positioning: Daily Transaction adalah data *daily close*, *volume*, dan *market cap* dengan window sampai 90 hari — bukan feed real-time. Jangan disebut “real-time market data” di pitch maupun UI; positioning yang akurat adalah “current/near-current research data + historical market context”, supaya ekspektasi user (dan panel juri) tidak salah arah ke “terminal trading”.

BAGIAN 09

Revisi Roadmap 4 Minggu

Minggu	Fokus	Deliverable (perubahan dari v1.0 ditandai)
1	Spine	Sama seperti v1.0 (Planner + DAG engine, skema Evidence Store) + Intent Router berbasis LLM sejak awal , dibatasi ketat ke structured intent (Bagian 03) yang di-mapping ke Template Library — bukan rule-based dulu lalu migrasi (lihat alasan di Bagian 03) + tool per agent dikunci sesuai pemetaan Bagian 08 , mulai dari Financial Researcher (Company Report, Quarterly Financials)
2	Debate + Judge + validasi	Sama seperti v1.0 (Market & News Researcher paralel, Bull+Bear+Debate 1 ronde, evidence validator wajib) + /screen mulai dibangun paralel (reuse Financial Researcher + Company Screener, tambah logic ranking sederhana)
3	UI + robustness	Sama seperti v1.0 (live UI, caching, fallback data) + refinement akurasi Intent Classifier (bukan migrasi pendekatan — sudah LLM sejak Minggu 1), NL query jadi input utama di UI (bukan hanya slash command) + /screen selesai dengan reframing kriteria historis (Bagian 07) + GUI expand/collapse per section (Planner/Researcher/Evidence/Bull-Bear/Judge), bukan interactive execution graph engine
4	Perluasan roadmap + polish	Sama seperti v1.0 (/compare, model routing 2 tier, dokumentasi) + Agent Configurator versi ringan (checklist domain/skill yang sudah ada, tanpa kolom instruksi bebas — lihat contoh dilarang di Bagian 05) sebagai bukti konsep; command lain tetap sebagai “next” di pitch

BAGIAN 10

Risiko Tambahan & Kesimpulan

Empat risiko baru muncul akibat perubahan di addendum ini, melengkapi tabel risiko Bagian 12 v1.0:

Risiko	Dampak bila diabaikan	Mitigasi
Intent misclassification	Router salah merutekan pertanyaan ke template yang keliru	Fallback klarifikasi eksplisit (“maksud kamu evaluasi BBKA, atau screening semua bank?”), bukan menebak; command slash tetap tersedia sebagai override manual
Configurator jadi celah scope creep	Tim tergoda menambah opsi konfigurasi terus-menerus mendekati deadline	Kunci daftar data source & skill yang bisa dipilih di awal Minggu 4; tidak menambah opsi baru H-3 sebelum demo
Risiko regulasi meningkat pada /screen	Output cross-ticker terbaca sebagai rekomendasi daftar saham	Reframing kriteria historis (Bagian 07) + disclaimer menonjol, wajib sebelum /screen didemokan
GUI execution graph over-scope	Waktu Minggu 3 habis untuk graph engine interaktif alih-alih robustness agent	Batasi ke expand/collapse per section (Bagian 09, Minggu 3); klik node detail (tools/evidence/durasi) cukup sebagai panel statis, bukan graph engine general-purpose

Kesimpulan Revisi

Addendum ini tidak mengubah fondasi v1.0 — Evidence Store, validasi evidence, dan Judge tetap seperti semula. Yang berubah adalah bagaimana user **masuk** ke sistem (natural language, bukan hafalan command), bagaimana **ekstensibilitas** ditangani (Agent Library yang tumbuh dari tim + Agent Configurator terbatas, bukan authoring bebas per-user), dan — sejak v1.2 — bagaimana **tool dipetakan** ke API yang benar-benar terdokumentasi (Bagian 08), bukan diasumsikan dari nama endpoint. Dengan begitu, kata “harness” tetap punya makna teknis yang jujur — komposabilitas dari primitives yang tervalidasi — tanpa mengorbankan empat pilar yang sudah terbukti solid di v1.0.